Business Intelligence

Proyecto final · Entrega 3

Modelo predictivo

RetailBI

Integrante	Código
Juan David Pardo Gutierrez	506241031
Linda Valentina Quintero Quiroga	506241056
Daniel Felipe Rodríguez Angulo	506241129

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	13/11/2026
Repositorio	https://github.com/damoelrrr/BI-Entrega-3-Equipo.506241031-506241056-506241129
Entorno del modelo	Python 3.12 en Jupyter y Google Colab, con pandas y scikit-learn; PostgreSQL 16.15 y Power BI Desktop

Resumen de la entrega

Esta entrega responde una pregunta de tipo BA: cuántas unidades de cada producto se venderán en cada tienda el próximo mes, para que compras decida cuánto pedir. El problema es de regresión. Se extrajeron 5.400 registros del data warehouse de la Entrega 2 (5 tiendas, 30 productos y 36 meses), se entrenaron una regresión lineal y un bosque aleatorio con datos de abril de 2023 a diciembre de 2024 y se evaluaron con los 12 meses de 2025.

Se eligió la regresión lineal: su error medio (MAE) es de 7,22 unidades por tienda, producto y mes, frente a 7,37 del bosque aleatorio y 8,74 del pronóstico ingenuo, con lo que se cumple el criterio de éxito (MAE menor o igual a 8). Para diciembre de 2025 el modelo pronostica 4.672 unidades en la cadena frente a 4.874 reales; compras debería pedir la predicción de cada tienda y producto más un margen de hasta 7 unidades. Las predicciones están en la tabla dw.pred_ventas_unidades y en una página nueva del tablero. Las cifras provienen de datos sintéticos y demuestran el funcionamiento del modelo; no corresponden a ventas reales de una empresa.

1. Comprensión del negocio

1.1 Pregunta y decisión

Pregunta BA: ¿cuántas unidades de cada producto se venderán en cada tienda el próximo mes?

Corresponde a la P4 de la tabla 1.3 de la Entrega 1 («¿Qué nivel de ventas podría esperarse para los próximos meses a partir del historial?»), precisada como unidades por producto y tienda para el mes siguiente, que es el nivel en el que compras hace los pedidos. Se elige porque las preguntas P0 a P3 del tablero de la Entrega 2 miran hacia atrás (qué vendimos y cuándo), mientras que esta mira hacia adelante. Es relevante porque la Entrega 2 mostró diferencias grandes entre tiendas (Kennedy vendió 45,5 % más unidades que Usaquén) y una variación mensual marcada, con diciembre como el mes más alto.

Decisión que apoya: el gerente de compras usará la predicción de cada tienda y producto para definir el pedido mensual, evitando tanto el desabastecimiento en los meses altos como el exceso de inventario en los bajos.

1.2 Variable objetivo y tipo de problema

Elemento	Respuesta
Variable objetivo	Unidades vendidas por tienda, producto y mes (unidades)
Tipo de problema	Regresión, porque se predice una cantidad
Unidad de predicción	Una predicción por tienda, producto y mes (5 tiendas × 30 productos × 12 meses de prueba = 1.800 predicciones)

1.3 Criterio de éxito

El modelo elegido tendrá éxito si su MAE sobre el conjunto de prueba es menor o igual a 8 unidades por tienda, producto y mes (cerca de un tercio de las 24 unidades que se venden en promedio) y, además, es menor que el MAE del pronóstico ingenuo, que usa el promedio de los tres meses anteriores.

2. Comprensión de los datos

2.1 Consulta de extracción

```
-- Conjunto de datos del modelo: unidades vendidas por tienda, producto y mes.
-- Granularidad: una fila por tienda x producto x mes (5 x 30 x 36 = 5.400 filas).
-- Se parte de todas las combinaciones (LEFT JOIN) para que los meses sin ventas
```

```
-- aparezcan con 0 unidades y no se pierdan.
-- Ejecutar conectado a retailbi_dw (esquema dw).
WITH meses AS (
    SELECT anio, mes, anio_mes, MIN(fecha_key) AS fecha_key   -- fecha_key del primer día del mes
    FROM dw.dim_fecha
    GROUP BY anio, mes, anio_mes
),
ventas AS (
    SELECT d.anio_mes, f.tienda_key, f.producto_key,
           SUM(f.cantidad)    AS unidades,
           SUM(f.venta_bruta) AS venta_bruta,
           SUM(f.descuento)   AS descuento
    FROM dw.fact_ventas f
    JOIN dw.dim_fecha d ON d.fecha_key = f.fecha_key
    GROUP BY d.anio_mes, f.tienda_key, f.producto_key
)
SELECT m.fecha_key, m.anio, m.mes, m.anio_mes,
       t.tienda_key,   t.nombre_tienda,
       p.producto_key, p.nombre_producto, p.categoria,
       COALESCE(v.unidades, 0)    AS unidades,
       COALESCE(v.venta_bruta, 0) AS venta_bruta,
       COALESCE(v.descuento, 0)   AS descuento
FROM meses m
CROSS JOIN dw.dim_tienda   t
CROSS JOIN dw.dim_producto p
LEFT JOIN ventas v ON v.anio_mes = m.anio_mes
                  AND v.tienda_key = t.tienda_key
                  AND v.producto_key = p.producto_key
WHERE t.tienda_key <> -1
  AND p.producto_key <> -1
ORDER BY t.tienda_key, p.producto_key, m.anio_mes;
```

La consulta resume fact_ventas por mes y la une con dim_fecha, dim_tienda y dim_producto. Parte del producto cartesiano de meses, tiendas y productos y usa LEFT JOIN con las ventas, de modo que un mes sin ventas aparecería con cero unidades en lugar de desaparecer. Excluye las filas «Desconocido» (llave −1) de las dimensiones. El archivo está en modelo/extraccion.sql.

2.2 Descripción del conjunto de datos

Número de registros: 5.400. **Periodo cubierto:** enero de 2023 a diciembre de 2025 (36 meses).

Variable	Tipo	Papel	Origen (tabla.columna)	Descripción
unidades	Numérica	Objetivo	dw.fact_ventas.cantidad	Suma de unidades del mes
nombre_tienda	Categórica	Entrada	dw.dim_tienda.nombre_tienda	Tienda (5)
categoria	Categórica	Entrada	dw.dim_producto.categoria	Categoría del producto (6)
mes	Numérica	Entrada	dw.dim_fecha.mes	Mes del año (1 a 12)
es_diciembre	Numérica (0/1)	Entrada (derivada)	dw.dim_fecha.mes	1 si el mes es diciembre
unidades_mes_ant_1, _2 y _3	Numérica	Entrada (derivada)	dw.fact_ventas.cantidad	Unidades 1, 2 y 3 meses atrás
promedio_3m	Numérica	Entrada (derivada)	dw.fact_ventas.cantidad	Promedio de los 3 meses anteriores
fecha_key, anio, anio_mes	Entero / texto	No entra al modelo	dw.dim_fecha	Identifican el mes y permiten la división temporal
tienda_key, producto_key	Entero	No entra al modelo	dw.dim_tienda, dw.dim_producto	Llaves para unir las predicciones
nombre_producto	Texto	No entra al modelo	dw.dim_producto.nombre_producto	Nombre del producto

Variable	Tipo	Papel	Origen (tabla.columna)	Descripción
venta_bruta, descuento	Numérica	No entra al modelo	dw.fact_ventas	Solo se conocen al cerrar el mes; usarlas filtraría el futuro

2.3 Distribución de la variable objetivo

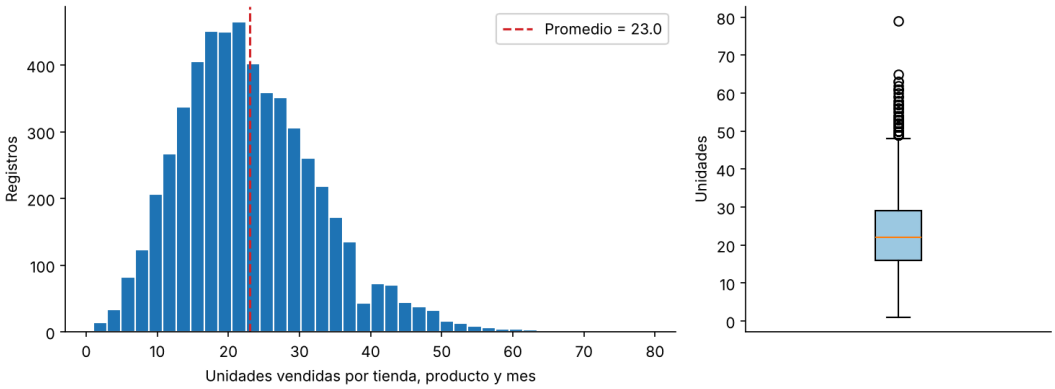


Figura 1. Distribución de las unidades vendidas por tienda, producto y mes.

Las unidades van de 1 a 79, con promedio de 23,0 y mediana de 22. La distribución es unimodal y algo asimétrica hacia la derecha. Por la regla del rango intercuartílico (límite superior de 48,5 unidades) hay 75 registros atípicos, el 1,4 % del total, que corresponden a picos de venta y no a errores de captura.

2.4 Análisis exploratorio

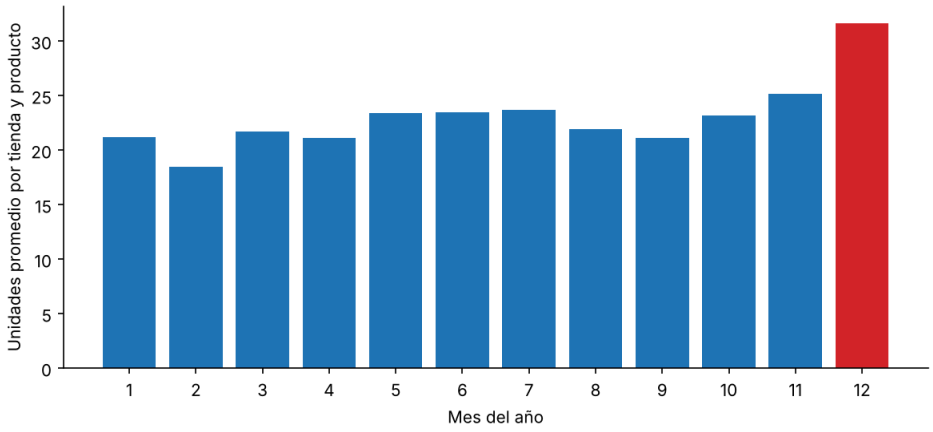


Figura 2. Unidades promedio por tienda y producto, según el mes del año.

Diciembre es el mes más alto: 31,6 unidades en promedio, un 37 % por encima del promedio anual (23,0). Febrero es el más bajo (18,5). El mes del año se relaciona claramente con la variable objetivo, sobre todo por el pico de diciembre.

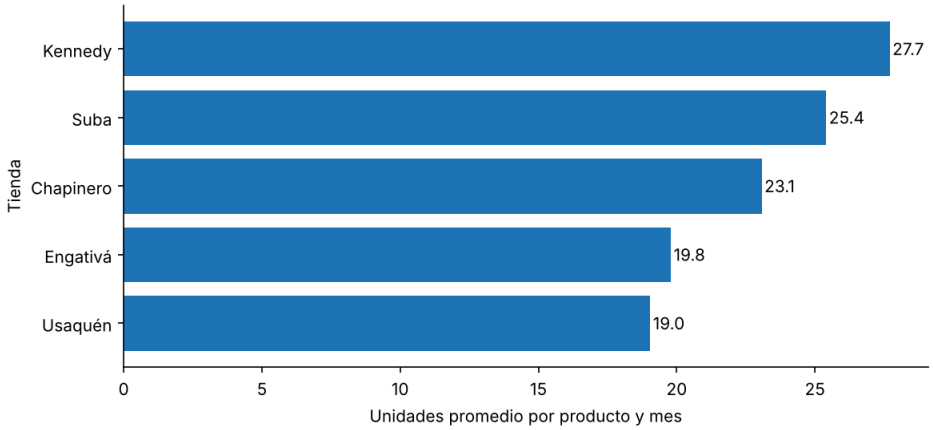


Figura 3. Unidades promedio por producto y mes, según la tienda.

Kennedy lidera con 27,7 unidades por producto y mes y Usaquén es la última con 19,0 (Kennedy vende 45,5 % más). Las tiendas tienen niveles de venta distintos y estables, así que la tienda es una variable relevante para predecir. En cambio, las categorías se venden casi igual (entre 22,4 y 23,2 unidades).

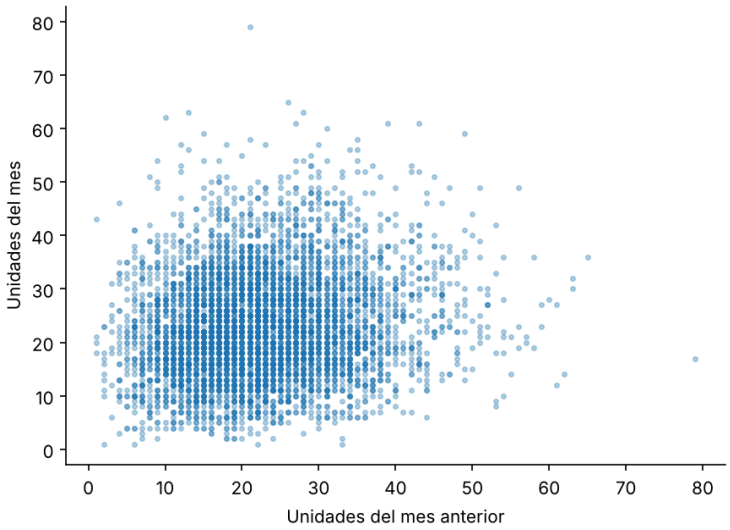


Figura 4. Unidades del mes frente a las unidades del mes anterior.

La relación es débil: la correlación entre las unidades de un mes y las del mes anterior es de 0,15 y la nube de puntos no muestra una tendencia clara. La venta de cada producto fluctúa alrededor de un nivel propio de cada tienda, de modo que el último mes aporta poca información.

3. Preparación de los datos

3.1 Limpieza y transformación

Tratamiento	Variable(s)	Qué se hizo	Registros afectados
Nulos en la extracción	Todas	No hay nulos: la consulta reemplaza con cero los meses sin ventas y ninguno quedó vacío	0

Tratamiento	Variable(s)	Qué se hizo	Registros afectados
Nulos por rezagos	unidades_mes_ant_1 a 3 y promedio_3m	Los tres primeros meses de cada serie no tienen historia; se eliminan esas filas (5.400 pasan a 4.950)	450
Atípicos	unidades	Se detectan con el rango intercuartílico (límite 48,5 unidades). Se conservan porque son picos reales, 35 de ellos en diciembre	75 detectados, 0 eliminados
Codificación categórica	nombre_tienda y categoria	One-hot con OneHotEncoder, ajustado solo con el conjunto de entrenamiento: 5 columnas de tienda y 6 de categoría	4.950

3.2 Variables derivadas

Variable nueva	Cómo se calcula	Por qué puede ayudar	¿Se conoce antes del hecho?
unidades_mes_ant_1, _2 y _3	Unidades del mismo producto en la misma tienda 1, 2 y 3 meses atrás	La demanda reciente puede anticipar la del mes siguiente	Sí, son ventas ya cerradas
promedio_3m	Promedio de las tres anteriores	Suaviza las fluctuaciones de un solo mes	Sí
es_diciembre	1 si el mes es diciembre y 0 en los demás	Captura el pico de diciembre que muestra la exploración	Sí, el calendario se conoce

3.3 División en entrenamiento y prueba

Conjunto	Registros	Periodo o proporción
Entrenamiento	3.150	Abril de 2023 a diciembre de 2024 (21 meses; 64 %)
Prueba	1.800	Enero a diciembre de 2025 (12 meses; 36 %)

La división es temporal: se entrena con el pasado y se prueba con el año más reciente. Los tres primeros meses de 2023 no entran porque no tienen rezagos.

4. Modelado

4.1 Algoritmos

Algoritmo	Por qué se eligió	Parámetros usados
Regresión lineal	Línea base simple y explicable: cada coeficiente indica cuántas unidades cambia la predicción, lo que permite explicárselo a compras	Valores por defecto de scikit-learn (con intercepto)
Bosque aleatorio	Captura relaciones no lineales e interacciones (por ejemplo, el pico de diciembre por tienda) y es robusto a los atípicos	n_estimators = 300, min_samples_leaf = 5, random_state = 42; el resto por defecto (max_depth sin límite, max_features = 1,0)

Variables de entrada (las mismas para ambos algoritmos): unidades_mes_ant_1, unidades_mes_ant_2, unidades_mes_ant_3, promedio_3m, mes, es_diciembre, nombre_tienda y categoria. Los dos algoritmos se entrenan con los mismos 3.150 registros de entrenamiento y la misma transformación (ColumnTransformer con one-hot para las dos categóricas).

5. Evaluación

5.1 Métricas sobre el conjunto de prueba

Regresión

Algoritmo	MAE	RMSE	Interpretación en unidades del caso
Regresión lineal	7,22	9,19	Se equivoca en promedio 7,2 unidades por tienda, producto y mes, el 30 % de las 24,5 unidades que se vendieron en promedio. El RMSE de 9,2 indica que hay errores grandes en algunos meses: el error medio sube a 8,5 unidades en diciembre y a 8,1 en mayo, frente a 6,5 en febrero.
Bosque aleatorio	7,37	9,37	Se equivoca en promedio 7,4 unidades (30 % del promedio real). Su RMSE de 9,4 muestra el mismo patrón: errores ocasionalmente grandes en los meses de mayor venta.

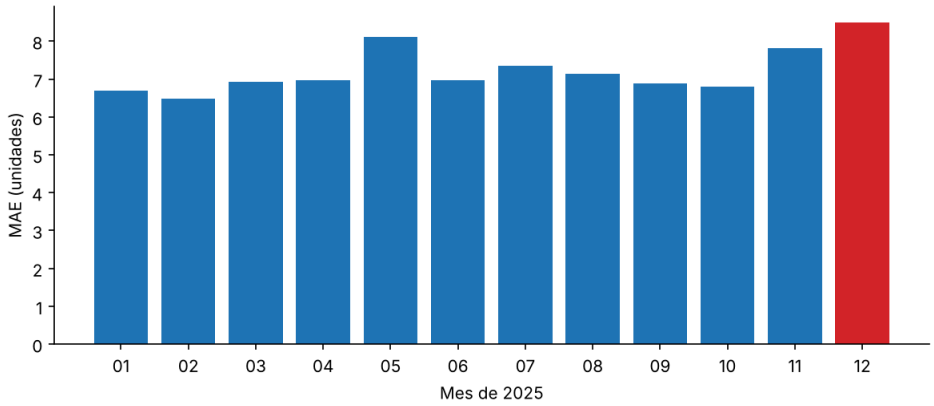


Figura 5. Error medio absoluto (MAE) de la regresión lineal por mes de 2025.

5.2 Comparación y elección

Se elige la regresión lineal: su MAE es 0,15 unidades menor y su RMSE es 0,18 unidades menor que los del bosque aleatorio sobre el mismo conjunto de prueba. La diferencia es pequeña, casi un empate, y por eso pesa también que la regresión lineal es más simple y se puede explicar con sus coeficientes. Frente al pronóstico ingenuo (promedio de los tres meses anteriores, MAE de 8,74 y RMSE de 10,91), el modelo reduce el error en 1,52 unidades, es decir, un 17 %.

5.3 Variables más importantes

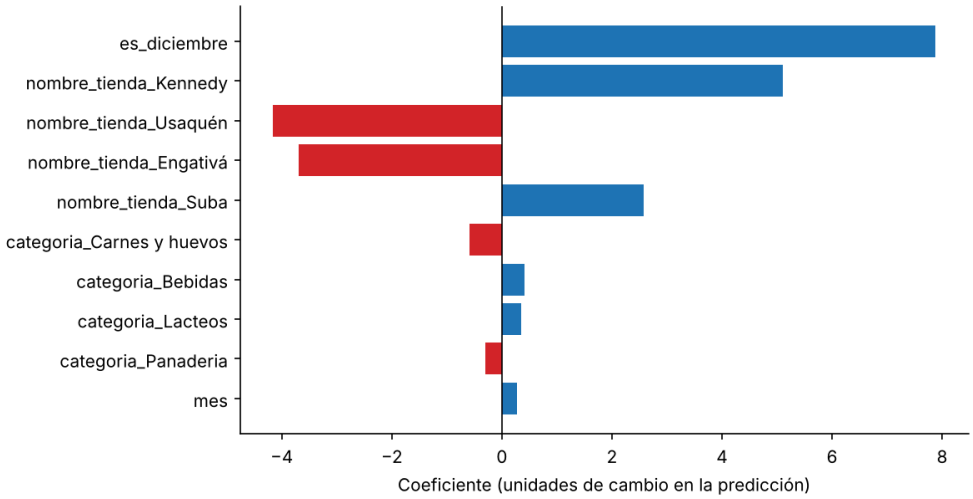


Figura 6. Variables con mayor peso en la regresión lineal (coeficientes con signo).

El efecto más grande es es_diciembre: en diciembre se venden 7,9 unidades más por tienda y producto que en el resto del año. Después viene la tienda: Kennedy suma 5,1 unidades y Suba 2,6, mientras que Usaquén resta 4,2 y Engativá 3,7. La categoría casi no cambia la predicción (coeficientes menores a 0,6 unidades) y las ventas de los meses anteriores prácticamente no pesan (coeficientes entre −0,02 y 0,01). Es decir, en estos datos la demanda depende del nivel de cada tienda y de la temporada, no de lo que pasó el mes anterior.

5.4 Criterio de éxito

Criterio (sección 1.3)	Valor obtenido	¿Se alcanzó?
MAE menor o igual a 8 unidades y menor que el del pronóstico ingenuo	MAE de 7,22 unidades (pronóstico ingenuo: 8,74)	Sí

5.5 Respuesta a la pregunta de negocio

Para diciembre de 2025 el modelo pronostica 4.672 unidades en toda la cadena: Kennedy 1.084, Suba 1.009, Chapinero 938, Engativá 826 y Usaquén 814. Las ventas reales fueron 4.874 unidades, así que el modelo se quedó 202 unidades corto (4 %): subestimó Suba en 71, Kennedy en 69, Engativá en 59 y Usaquén en 16, y sobreestimó Chapinero en 12. Los productos con más unidades pronosticadas en la cadena son Cerveza x6 y Gaseosa 1.5 L, con 159 cada uno.

Decisión que apoya: compras debe pedir, para cada tienda y producto, la predicción del modelo más un margen de seguridad de hasta 7 unidades (el MAE). El margen se necesita todos los meses y no solo en diciembre: en 2025 el modelo se quedó corto en el total del año (pronosticó 40.307 unidades frente a 44.020 reales, 8,4 % menos), con un faltante de 9,0 % de enero a noviembre y de 4,1 % en diciembre. En Kennedy el margen equivale a unas 210 unidades adicionales (30 productos × 7) sobre las 1.084 pronosticadas para diciembre, lo que lleva el pedido a unas 1.294 unidades, por encima de las 1.153 que realmente se vendieron. Estas cifras provienen de datos sintéticos y demuestran el funcionamiento del modelo.

6. Despliegue

6.1 Tabla de predicciones

Tabla: dw.pred_ventas_unidades. **Registros:** 1.800 (predicciones del conjunto de prueba, 2025). Script: DW/ddl/09_pred_ventas_unidades.sql.

Columna	Tipo	Descripción
pred_key	BIGINT (llave primaria)	Identificador de la predicción, generado por la base
fecha_key	INTEGER (llave foránea)	Llave de dim_fecha; corresponde al primer día del mes
tienda_key	INTEGER (llave foránea)	Llave de dim_tienda
producto_key	INTEGER (llave foránea)	Llave de dim_producto
modelo	VARCHAR(40)	Algoritmo elegido (regresión lineal)
unidades_real	INTEGER	Unidades realmente vendidas en el mes
unidades_pred	NUMERIC(10,2)	Unidades pronosticadas por el modelo
error_abs	NUMERIC(10,2)	Valor absoluto de la diferencia entre real y pronóstico

6.2 Página de predicciones en el tablero

La página «Predicción de unidades vendidas frente a valores reales (2025)» del archivo dashboard/RetailBI_tablero.pbix tiene tarjetas con las unidades reales, las pronosticadas y el MAE; un gráfico de líneas con el pronóstico y lo real por mes; barras agrupadas por tienda; y una tabla de detalle por producto. Se puede filtrar por tienda y por categoría con segmentadores.

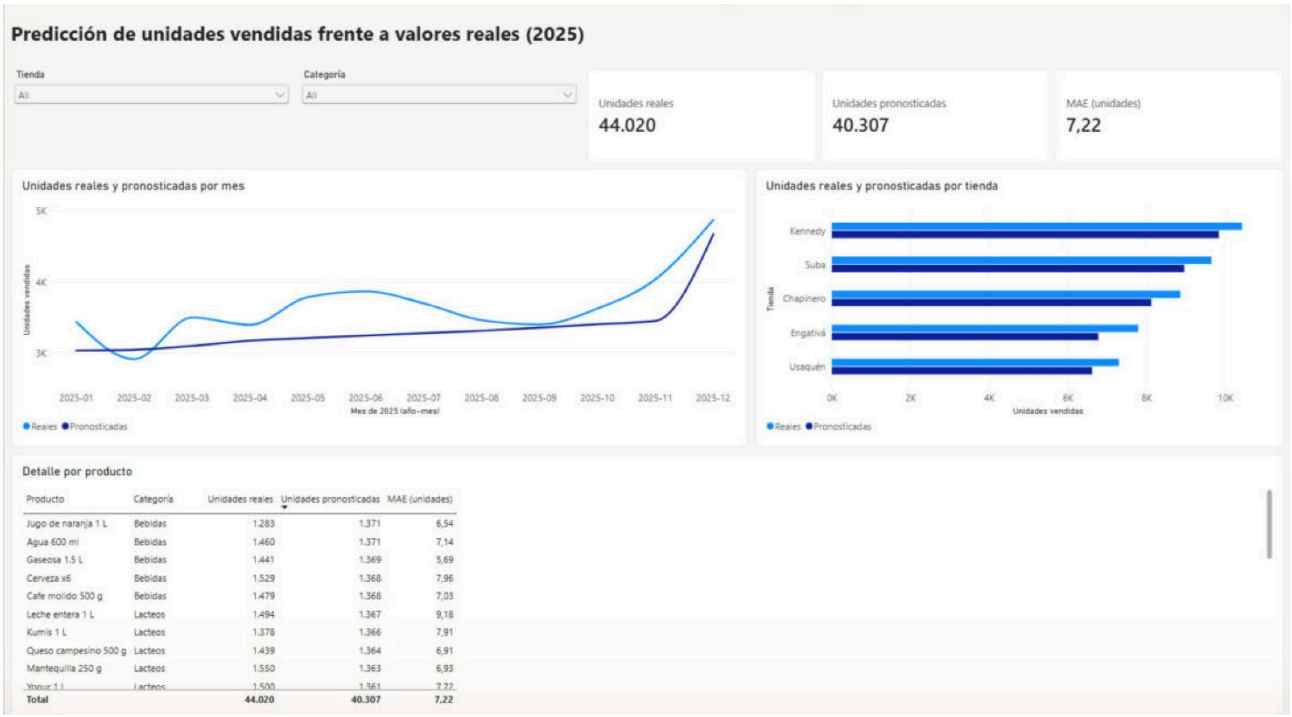


Figura 7. Página «Predicción de unidades» del tablero RetailBI.